



**UNIVERSITÉ
DE GENÈVE**

CENTRE UNIVERSITAIRE
D'INFORMATIQUE



**UNIVERSITÉ
DE GENÈVE**

FACULTÉ DES SCIENCES

EduRisk: un pipeline pour simplifier l'accès à la connaissance du risque. Rapport pour le groupe N03 :



Daniel Nissille



Open Science automne 2025

Sous la supervision du Prof. François Grey

Daniel Nissille, Nam Thang Nguyen, Joël Favre, Mihaela Satcovschi, Loic Kiluangu

Et avec la participation durant le Hackathon de Thibaut De Mallac de Vessac et Julie Hyunh Khanh-Thu

Table des matières

Résumé du sujet concerné :	3
Introduction de la problématique :	4
Méthodologie :	4
1) Idée conceptuelle globale du pipeline :.....	4
2) Architecture et pipeline technique du chatbot EduRisk.....	5
Architecture logicielle du chatbot.....	6
Modèle de données : structure attendue d'une FactsBox.....	8
3) Idée conceptuelle globale de la phase de test :.....	8
Results (prototype, mock up) :	9
Exemple 1 (vaccin contre la grippe).....	9
Exemple 2 (Images sur les paquets de cigarettes).....	11
Résumé et perspective d'avenir :	14
Compte rendu du travail par membre :	15
Daniel Nissille :.....	15
Nam Thang Nguyen :.....	15
Annexes.....	16
Interview 1 :.....	16
Interview 2 :.....	17
Interview 3 :.....	18
Bibliographie :	20
Figures:.....	21

Résumé du sujet concerné :

Nous vivons à une époque dans laquelle il n'a jamais été autant donné à l'humanité d'être bombardé d'informations. Réseaux sociaux, plateformes de diffusion ou encore journaux, partout des digits, des calculs et des pourcentages. Mais lorsqu'il est question d'aborder des questions de risques les choses se complexifient. Le cerveau humain n'est pas efficace pour traiter l'information probabiliste et même des scientifiques peuvent être biaisés ou égarés par des résultats peu intuitifs surtout s'ils n'ont pas été formés pour ce faire. (**Source des tests de résilience effectués au niveau des uni**) [1]. Effectivement si votre magasin favori affiche : « Méga réduction de -40% sur les déjà -40% » vous aurez vite fait de vous dire qu'il s'agit d'une réduction de 80% alors qu'en réalité elle n'est que de 64%. Il en va de même pour des cas concrets de présentation des risques : « Ce vaccin protège à hauteur de 50% » ou encore « Prendre l'avion est beaucoup moins risqué que la voiture. » On comprend ici qu'il faut pouvoir décortiquer l'information pour la rendre plus intuitive, plus accessible dans son ensemble. Combien de personnes sont réellement malades et combien de ces malades peuvent espérer être réellement protégés ? Peut-on comparer de manière intuitive les risques de prendre l'avion avec ceux de prendre la voiture ? La « risk literacy » est justement un domaine qui cherche à mieux définir et rendre les questions liées au risque plus intuitives [2].

Figure 1 Une personne perdue devant la masse d'information du quotidien.



Introduction de la problématique :

La problématique initiale que nous avons choisis de traiter était : “**EduRisk: Cognitive Models for Risk Literacy** AI tools explore how education shapes risk perception and decision-making, using open data to improve teaching on uncertainty and behavioral resilience.”

Il n’a pas été aisé de travailler cette problématique complexe qui demandait à être décomposée en plusieurs points. La “risk literacy” n’est en effet pas juste traductible en français par compréhension du risque. C’est une véritable science combinant maths, psychologie et esprit critique. [2] L’idée de base ici étant visiblement de parvenir à évaluer l’efficacité de l’enseignement d’une méthode permettant d’améliorer la résilience devant les questions de risques. Cela pouvant tant avoir un effet sur les décisions communes du quotidien que sur des décisions impactant notre parcours de vie. Un point également important est l’intégration d’outils IA et de données ouvertes.

Pendant le Hackathon nous avons rapidement été confrontés à un problème initial. Avant même de parler de risque, il faut déjà définir un domaine concerné par ce risque (Médecine, économie...) et avec cela il faut aussi pouvoir trouver des publications associées. Lors de nos recherches nous avons réalisé que ces dites publications pour autant qu’elles soient accessibles n’étaient pas toujours très intuitives. Nous avons par conséquent décidé de nous focaliser sur une première étape fondamentale : l’extraction des données liées au risque. Avec l’objectif de pouvoir enseigner ou clarifier l’information, nous avons imaginé de rendre les données extraites plus intuitives. Nous avons aussi discuté des méthodes qui pourront être mises en place afin de tester l’efficacité du procédé que nous cherchons à développer.

En clair : Nous avons développé l’idée d’une démarche permettant de simplifier l’accès et la compréhension à la connaissance scientifique traitant du risque. Notre pipeline utilise des méthodes de risk literacy adjointes d’un traitement d’extraction par IA. Avec l’intention de pouvoir dans un deuxième temps aussi évaluer l’efficacité de la méthode considérée.

Méthodologie :

1) Idée conceptuelle globale du pipeline :

La discussion avec Madame Kerstin Preuschoff et deux experts en IA nous a conduit à revoir à la baisse la technicité de notre pipeline. Ainsi nous en sommes arrivés à la démarche globale suivante :

- 1) Extraire l’information contenue dans une publication traitant du risque, on parle ici de « scraping IA ».

- 2) Représenter l'information extraite de manière intuitive en utilisant des techniques développées par la « risk literacy ». Par exemple les « facts box » de G.Gigerenzer. [4]
- 3) Tester l'efficacité de la méthode utilisée à l'aide d'un questionnaire et deux groupes tests.
- 4) Ces trois derniers points ayant à être le plus ouverts possible et donc être disponibles gratuitement et avec un maximum de transparence.

L'idée d'appliquer les facts box pour présenter des données médicales n'est pas nouvelle [3] mais l'approche IA pour les construire rend le cas plus user-friendly. Néanmoins, l'idée de notre démarche n'est pas de laisser un chatbot effectuer des recherches à notre place, mais plutôt de lui fournir directement les publications scientifiques d'intérêts. Cela ayant pour avantage de ne pas tomber sur des résultats qui seraient hallucinés puisque c'est visiblement un problème actuel [7] et facilitera aussi les éventuelles améliorations futures de solidification des résultats.

Dans cette démarche globale, le chatbot EduRisk joue un rôle central en tant qu'interface entre les facts boxes générées et l'utilisateur final. La requête de l'utilisateur est d'abord analysée afin d'identifier l'intention et le contexte de la demande. En fonction de cette intention, la facts box pertinente est récupérée et interprétée. Les informations issues de cette facts box sont ensuite combinées à la question de l'utilisateur dans un prompt structuré, envoyé à un modèle de langage. Le chatbot génère alors une réponse textuelle visant à expliquer les risques de manière claire et intuitive. Cette réponse peut enfin servir d'entrée au module de génération de user stories.

Un prototype de ce chatbot a été implémenté durant le hackathon afin de valider la faisabilité de cette pipeline conceptuelle. Le code source est disponible publiquement sur GitHub <https://github.com/Nam-ngn/HackademiA-2025-chatbot>.

2) Architecture et pipeline technique du chatbot EduRisk

Le prototype du chatbot EduRisk s'appuie initialement sur un template d'architecture de type Retrieval-Augmented Generation (RAG), conçu pour exploiter des documents textuels non structurés, en particulier des publications scientifiques au format PDF (<https://github.com/pixegami/simple-rag-pipeline>). Dans sa version originale, ce pipeline reposait exclusivement sur l'indexation et la recherche sémantique de passages extraits de ces documents.

Dans le cadre de ce projet, cette architecture a été adaptée afin de prendre en compte des données structurées sous forme de fichiers CSV, représentant des facts boxes. Cette extension permet d'exploiter directement des données de risque pré-extraites et normalisées, facilitant leur interprétation par le chatbot et réduisant la dépendance à une extraction dynamique à partir de documents bruts. Le pipeline RAG a ainsi été enrichi pour combiner des sources non structurées (PDF) et

structurées (facts boxes), tout en conservant une séparation claire entre récupération des données et génération des réponses par le modèle de langage.

Architecture logicielle du chatbot

Le chatbot EduRisk repose sur une architecture logicielle modulaire organisée sous la forme d'une pipeline de traitement conversationnel. Cette architecture a pour objectif de séparer clairement les rôles des différentes composantes du système. Le chatbot agit comme un intermédiaire entre l'utilisateur et des données de risque déjà structurées en amont, notamment sous la forme de *facts boxes*.

L'échange avec l'utilisateur se fait par une interface conversationnelle, qui constitue le point d'entrée et de sortie du système. Cette interface se limite à transmettre les messages entre l'utilisateur et le backend, ainsi qu'à afficher les réponses produites. Elle ne contient aucune logique de traitement, ce qui permet de séparer clairement l'interface utilisateur des mécanismes internes du chatbot.

Le fonctionnement interne est piloté par un orchestrateur conversationnel. Celui-ci coordonne les différentes étapes du traitement et conserve les informations nécessaires au suivi de la conversation, comme l'historique des échanges, le contexte courant ou les éléments déjà utilisés lors des interactions précédentes (par exemple la *facts box* en cours ou le niveau de détail souhaité). Cette gestion du contexte permet de produire des réponses cohérentes tout au long d'un dialogue comportant plusieurs échanges.

Le traitement d'une requête commence par une analyse de l'intention de l'utilisateur. Ce module cherche à comprendre le type de question posée, par exemple une demande d'explication générale, une comparaison entre plusieurs options, une clarification d'un chiffre ou l'interprétation d'une information précise. Cette étape est réalisée indépendamment des données de risque, afin d'identifier quelles informations seront nécessaires pour répondre à la question.

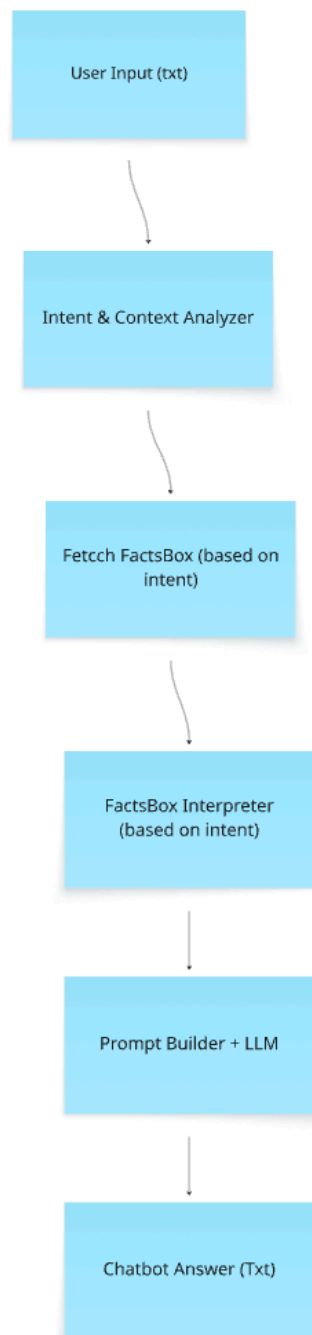
Une fois l'intention identifiée, le chatbot récupère les données pertinentes sous la forme d'une *facts box*. Ces *facts boxes* sont des structures de données contenant des résultats quantitatifs issus de publications scientifiques, tels que des risques absolus et relatifs, des bénéfices attendus ou des effets indésirables. L'utilisation de données structurées permet d'éviter que le modèle de langage génère lui-même des valeurs numériques.

Les informations contenues dans la *facts box* sont ensuite traitées par un module d'interprétation et de mise en forme. Ce module harmonise les formats numériques, transforme les probabilités en fréquences plus faciles à comprendre et calcule, si nécessaire, des indicateurs simples comme les différences absolues de risque. Les données sont ainsi préparées pour être expliquées clairement à l'utilisateur.

La réponse est ensuite générée à l'aide d'un modèle de langage, à partir d'un prompt construit de manière contrôlée. Ce prompt rassemble la question de l'utilisateur, le

contexte de la conversation, les données préparées issues de la *facts box* et un ensemble de règles imposant un style clair, un ton neutre et une distinction explicite entre les différents types de risques. Le modèle de langage est utilisé uniquement pour reformuler et expliquer les informations, et non pour produire de nouvelles connaissances.

Enfin, la réponse générée fait l'objet d'un léger post-traitement afin d'améliorer sa lisibilité avant d'être présentée à l'utilisateur. Cette réponse peut également être transmise à un module de génération de *user stories*, permettant de proposer des mises en situation narratives destinées à faciliter la compréhension des informations de risque.



Modèle de données : structure attendue d'une FactsBox

Pour que le chatbot reste fiable, les facts boxes sont stockées et échangées sous forme structurée. Une facts box minimale contient :

Contexte / étude

- title (ou nom de l'intervention),
- source (référence publication),
- population (qui est étudié),
- duration (durée de suivi),
- sample_size (taille de l'échantillon, si disponible).

Comparaison intervention vs contrôle

- control_risk_abs : risque absolu groupe contrôle (ex. "6/100"),
- intervention_risk_abs : risque absolu groupe intervention (ex. "2/100"),
- risk_difference_abs : différence absolue (ex. "-4/100"),
- risk_ratio_rel ou risk_reduction_rel : indicateur relatif (ex. "60% de réduction relative").

Bénéfices / dommages

- benefits : liste ou texte structuré,
- harms / side_effects : liste ou texte structuré.

3) Idée conceptuelle globale de la phase de test :

Est-ce que quelqu'un a trouvé des exemples ?

Notre pipeline de test se voulait très simple : Etablir un questionnaire sur les résultats d'une publication traitant du risque et soumettre ce questionnaire à deux groupes. L'un ayant eu accès à un résultat simplifié par notre pipeline EduRisk et le second sans outil. Les performances de réponses seront alors comparées par exemple avec un test de Student [8]. Afin d'améliorer la

mesure de la capacité à prendre des décisions d'EduRisk la variable temporelle a aussi été considérée.

Results (prototype, mock up) :

Exemple 1 (vaccin contre la grippe)

Pour le 1er exemple, nous avons résumé nos attentes en un petit cas concret :

Joe est un senior et il aimerait savoir s'il est avantageux de se faire vacciner contre la grippe. Il a lu quelque part que le vaccin protégeait à 60% contre la grippe (influenza) et par conséquent il a l'impression que ce dernier est très efficace, voir même fondamentale. Puisqu'il est un peu sceptique Joe en a parlé à son médecin qui lui a alors recommandé une publication médicale «**Vaccines for preventing influenza in the elderly** » [5] Le problème pour Joe c'est qu'il ne comprend vraiment rien aux statistiques médicales. Avec notre pipeline EduRisk, Joe peut générer une fact box clair qui lui permettra de se faire un avis tranché sur la situation (figure 2).

Figure 3 un exemple de fact box intuitive de la publication de Demicheli et al., générée par ChatGPT.

✔ Fact-box « Si je suis une personne âgée (≥ 65 ans) : vacciner ou non contre la grippe »			
Situation / question	Sans vaccin	Avec vaccin	Réduction (absolue / relative)
Population étudiée	—	—	~ 5 000 personnes (8 études) <small>cochrane.org +1</small>
Risque de contracter la grippe sur une saison	~ 6 personnes sur 100	~ 2.4 personnes sur 100	Réduction absolue ≈ 3.6 points % Réduction relative ≈ 60 %
Risque de syndrome grippal (symptômes)	~ 6 personnes sur 100	~ 3.5 personnes sur 100	Réduction absolue ≈ 2.5 points % Réduction relative ≈ 42 %
Pour « 100 personnes âgées vaccinées » → combien évite-t-on un cas?	—	—	~ 1 cas de grippe évité pour 30 vaccinés ~ 1 cas de syndrome grippal évité pour 42 vaccinés

Interprétation simplifiée (en langage courant)

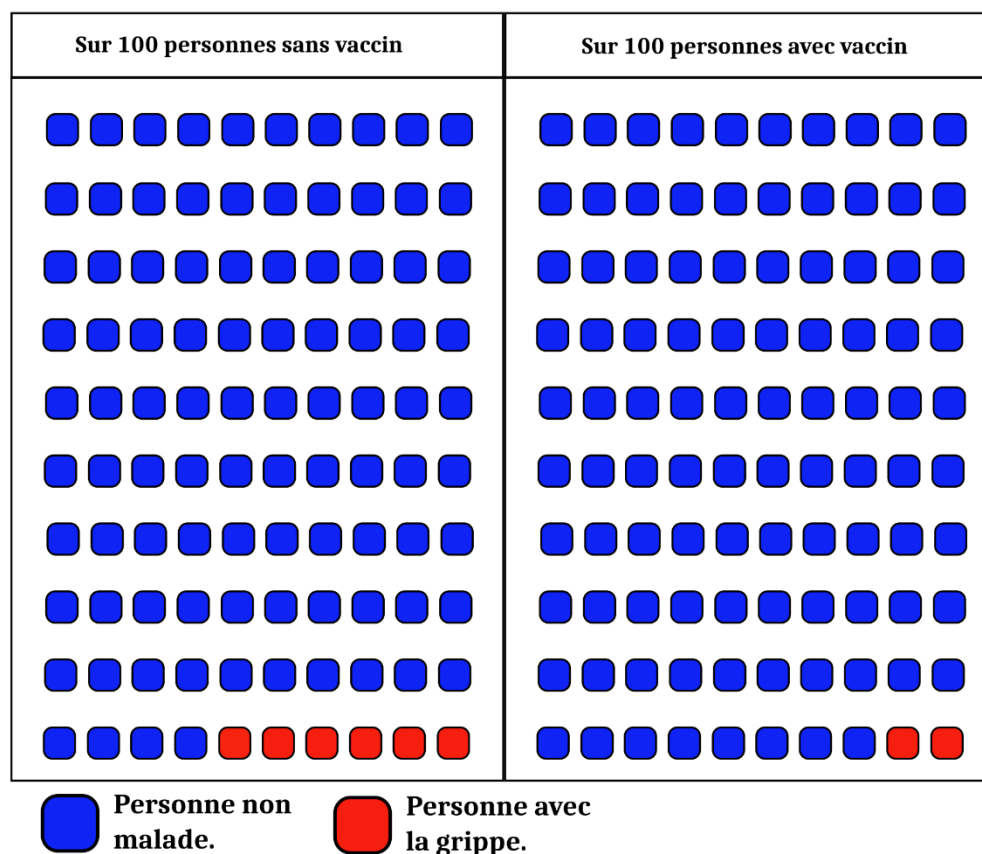
- Si 100 personnes âgées comme vous ne sont **pas vaccinées**, environ 6 vont attraper la grippe en une saison.
- Si ces 100 personnes sont **vaccinées**, environ 2 à 3 d'entre elles attraperont la grippe — soit **3 à 4 grippes évitées**.
- En moyenne, il faut vacciner **30 personnes âgées** pour prévenir **1 infection grippale** en une saison.

Note Figure 3 : La représentation des données sous la forme de fact box permet de montrer les ratios réels et de surmonter une technique souvent utilisée par les

industrielles pour vendre l'efficacité de leur produit. En effet dans ce cas le fait de se vacciner peut diminuer le nombre de contagion de 4 sur 100 et comme 6 personnes sur 100 risquent de tomber malade il est juste de dire que la réduction relative est de 60%. Mais on réalise tout de suite que cette manière de faire est plus « vendeuse » que de dire : 2 personnes tomberont malade au lieu de 6 sur 100. La simplification en langage courant et la mention du nombre de personnes totales dans l'étude augmente aussi la pertinence de l'analyse considérée. Joe a donc à présent une vision moins biaisée et plus intuitive de la situation, il pourra donc prendre une décision sincère et éclairée.

La représentation en fact box n'est pas la seule manière de procéder, il est aussi possible d'utiliser des représentations en graphiques dit intuitifs parfois plus visuels (Figure 4).

Figure 4 un exemple graphique intuitif.



Note pour la figure 4 : Ce graphique intuitif et simple construit à la main avec INKSCAPE [6] résume encore plus simplement les résultats discutés ci-dessus.

Ici il faut aussi montrer ce qu'on a déjà réussi à faire avec le code. On doit leur vendre du rêve ^^.

Exemple 2 (Images sur les paquets de cigarettes)

Pour le 2ème exemple, nous avons choisi un autre cas concret, à savoir celui des fumeurs. Nous avons décidé d'utiliser le chatbot que nous avons implémenté en lui fournissant les données open-source afin de rester transparent et pour qu'il n'hallucine pas. L'architecture et le fonctionnement du chatbot se trouvent dans la section "Méthodologie":

Joe est un senior. Il estime que les avertissements sur les paquets de cigarettes ne sont pas efficaces et il aimerait beaucoup améliorer leur effet. Avant cela, il a besoin d'une synthèse intuitive pour résumer ses informations scientifiques sur le sujet.

Joe va d'abord se rendre sur l'interface conversationnelle du chatbot. Il va remplir sa question et envoyer son prompt : "Quels sont les effets des avertissements visuels (images) sur les paquets de cigarette ?"

Chatbot Data

Pose une question au sujet du tabac

Question

Quels sont les effets des avertissements visuels (images) sur les paquets de cigarette ?

Envoyer

Figure 5 Interface visuelle du chatbot EduRisk

Le chatbot interprète cette requête comme une demande d'explication générale sur l'impact d'une intervention de santé publique. Il sélectionne alors la *facts box* correspondante, en extrait les informations pertinentes et les transforme en formats facilement compréhensibles. À partir de ces données, une réponse pédagogique, neutre et synthétique est générée, puis affichée à l'utilisateur.

Information	
Source: associations::avertissements-pictoriaux-sur-paquets-de-cigarettes	
Groupe	Risque Absolu
Groupe Contrôle	366 fumeurs sur 1078 ont tenté d'arrêter (34.0%, IC 95%: 31.1-36.8)
Groupe Intervention	428 fumeurs sur 1071 ont tenté d'arrêter (40.0%, IC 95%: 37.0-42.9)
Risques relatifs:	
• Augmentation de 29% des tentatives d'arrêt (OR 1.29, IC 95%: 1.09-1.54)	

Figure 6 Factbox générée par le chatbot EduRisk

Les résultats sont d'abord présentés à l'utilisateur sous la forme d'une factbox, structurée en sections clairement identifiées. Celle-ci commence par une comparaison entre un groupe contrôle et un groupe exposé aux avertissements visuels, en mettant en évidence les risques absolus et relatifs.

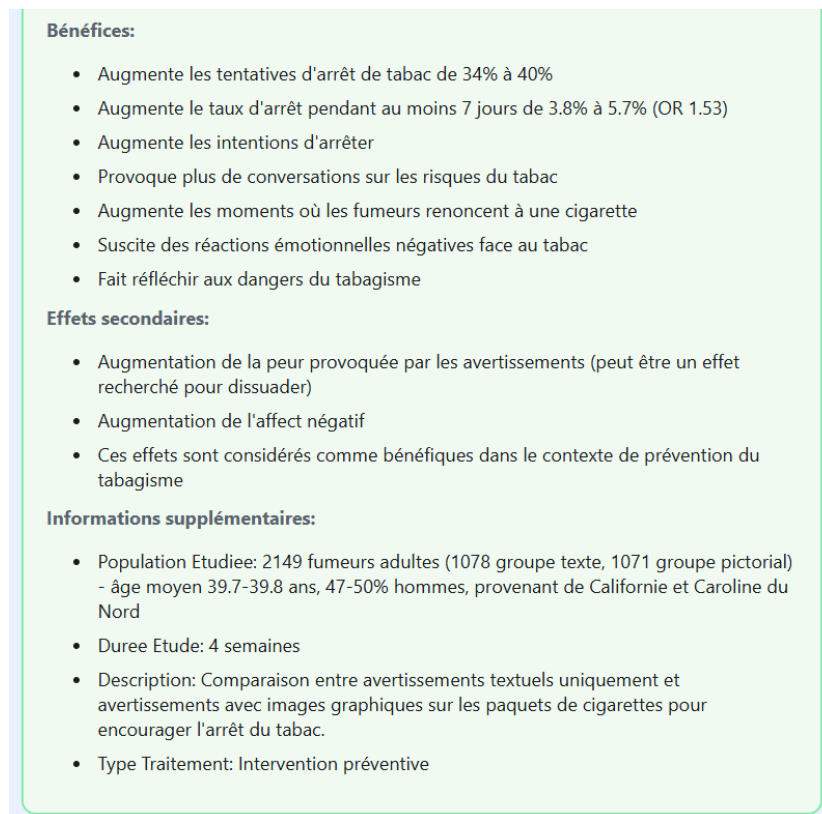


Figure 7 Bénéfices et effets secondaires des avertissements visuels sur les paquets de cigarettes

La factbox se poursuit ensuite par une synthèse qualitative des résultats. Une section dédiée aux bénéfices liste les principaux effets observés, en combinant des indicateurs chiffrés simples (par exemple l'augmentation des tentatives d'arrêt) et des effets comportementaux plus larges, comme l'augmentation des intentions d'arrêter ou des discussions autour des risques du tabac.

Les effets secondaires sont présentés séparément, afin de distinguer clairement les effets émotionnels induits par les avertissements visuels. Ils correspondent principalement à des réactions émotionnelles négatives, telles que la peur ou les effets négatifs suscités par les avertissements visuels. Bien que ces effets ne soient pas positifs du point de vue du ressenti individuel, ils sont explicitement contextualisés comme pouvant contribuer à l'objectif de prévention du tabagisme, en renforçant la prise de conscience des risques.

Enfin, la factbox se termine par des informations supplémentaires décrivant le cadre de l'étude (population, durée, type d'intervention). Ces éléments permettent à

l'utilisateur de mieux comprendre le contexte scientifique des résultats, sans entrer dans des détails méthodologiques complexes.

User Story

Julien, un fumeur de 30 ans, a été choqué par les images sur son paquet de cigarettes illustrant les dangers du tabac. Après avoir ressenti des émotions négatives en les voyant, il a décidé de parler à son médecin et, en l'espace de quelques semaines, il a tenté d'arrêter de fumer, rejoignant ainsi les 40 % de fumeurs qui envisagent une cessation après avoir vu ces avertissements visuels.

Les avertissements visuels (images) sur les paquets de cigarettes ont un impact significatif sur le comportement des fumeurs et leur perception des risques liés au tabagisme. Voici les principaux effets observés :

Figure 8 User Story générée par le chatbot EduRisk

Le chatbot affiche ensuite une user story visant à traduire les résultats statistiques en une situation concrète et compréhensible. Cette mise en récit illustre comment les effets observés dans les données peuvent se manifester à l'échelle individuelle. Le scénario met volontairement l'accent sur les réactions émotionnelles suscitées par les avertissements visuels et sur leur rôle possible dans le déclenchement d'une démarche d'arrêt, sans suggérer qu'un tel effet est systématique. Cette approche narrative complète la factbox en facilitant l'appropriation des résultats par l'utilisateur, tout en restant cohérente avec les données scientifiques présentées.

À terme, ce format pourrait être enrichi par des storyboards visuels accompagnant le texte, afin de renforcer encore la compréhension et l'impact pédagogique.

Conclusion

Globalement, les avertissements visuels sur les paquets de cigarettes augmentent significativement les tentatives d'arrêt et les discussions autour des risques du tabagisme, tout en provoquant des émotions qui peuvent inciter à une prise de conscience des dangers liés à cette pratique. Cependant, il est important de noter que l'augmentation de la peur et des émotions négatives peut varier d'une personne à l'autre.

🕒 22.23 s

Figure 9 Conclusion générée par le chatbot EduRisk

Pour finir, le chatbot propose une conclusion synthétique, qui résume les principaux enseignements issus des données présentées. Cette conclusion met en balance les effets bénéfiques observés, comme l'augmentation des tentatives d'arrêt et des échanges autour des risques du tabac, avec les effets émotionnels négatifs potentiellement induits. Elle rappelle également que ces effets peuvent varier selon

les individus, ce qui permet de maintenir un discours nuancé et non prescriptif. Cette étape finale vise à aider l'utilisateur à retenir l'essentiel, sans surinterpréter les résultats scientifiques.

Résumé et perspective d'avenir :

Ici faire une petite synthèse de ce qu'on est parvenu à faire et comment on imagine pouvoir faire avancer le projet dans le futur.

- Attention les fact boxes ne sont en rien une garantie que la publication de base est un bon travail, si cette dernière comporte des biais, la méthode employée ici ne les révélera pas.

Je suppose qu'ici on pourrait inclure les conclusions des études qu'on a trouvé (je trouve que ça fait une meilleure division de l'information avec laquelle on a travaillé)-M

Les points 6 et 7 seront traités durant l'écriture du rapport et la bibliographie est en dessous.

Compte rendu du travail par membre :

Daniel Nissille :

A grandement participé à la recherche de publications et d'informations pour mieux cerner la problématique. A œuvré à la compréhension et définition simple de la « risk literacy » et sur le comment transformer la problématique en un objectif atteignable dans les temps impartis. Travail conséquent sur la Rédaction du rapport et de la présentation. Construction du cas exemple de fact boxe sur la grippe et les exemples de référence.

Nam Thang Nguyen :

A assuré la mise en place des espaces collaboratifs nécessaires au travail de groupe (Drive, Miro, GitHub). A conçu le diagramme d'architecture du chatbot EduRisk et participé à la réflexion globale sur son intégration dans le pipeline du projet. A réalisé le scraping et l'extraction de données à partir de publications scientifiques, tant pour le texte que pour les tableaux, incluant un travail de vérification et de correction manuelle des erreurs issues de l'extraction automatique. A implémenté un prototype fonctionnel du chatbot pour l'analyse et l'exploitation des données de risque. A conduit 2 entretiens avec des experts en intelligence artificielle afin d'orienter les choix méthodologiques et techniques du projet. A contribué à la rédaction de la section *Architecture et pipeline technique du chatbot EduRisk* dans la méthodologie, l'exemple 2 (*Images sur les paquets de cigarettes*) de la partie *Results (prototype, mock-up)* ainsi que les annexes.

-A vous de jouer :

Annexes

Interview 1 :

Nam Thang Nguyen - 22.11.2025

Interview réalisée avec un chercheur en IA en personne:

Pourquoi l'open science est-elle si essentielle lorsqu'on travaille sur un projet lié à la "risk literacy" ?

L'open science permet d'accéder librement aux données, ce qui est indispensable quand on veut comprendre comment les individus perçoivent le risque ou l'incertitude. Sans données accessibles et ouvertes, il est très difficile d'évaluer objectivement les comportements, les biais ou l'efficacité de méthodes pédagogiques. Pour des projets comme EduRisk, l'open science est le socle de toute expérimentation crédible.

De manière plus globale, que permet l'open science dans le domaine de la résilience face à l'incertitude ?

Elle facilite la réplication, la comparaison et l'amélioration des modèles éducatifs. Lorsque des équipes partagent leurs publications, leurs protocoles et leurs sets de données, on peut vérifier leurs conclusions, tester d'autres contextes, et affiner progressivement ce qui fonctionne. Cela crée un écosystème où la compréhension du risque devient plus transparente et moins dépendante de pratiques opaques.

Dans notre projet, une étape clé est l'extraction de l'information issue d'articles scientifiques. Qu'est-ce qui pourrait rendre cette tâche complexe ?

L'absence de standardisation. Même au sein de revues scientifiques, la structuration varie énormément : tables avec lignes mal définies, graphiques intégrés en image, paragraphes fusionnés, scans de mauvaise qualité... L'IA peut aider, mais elle doit être combinée à des choix méthodologiques précis.

Quels outils recommanderiez-vous pour fiabiliser le scraping des textes ?

Pour le texte brut, un OCR de qualité comme *doctr* est indispensable. Pour les PDF numériques, *pdfplumber* fait un excellent travail. Mais dans tous les cas, il faut prévoir une couche de post-traitement : nettoyage, re-structuration des paragraphes et vérification manuelle ponctuelle. Une extraction irréprochable n'existe pas sans une validation humaine minimale.

Interview 2 :

Nam Thang Nguyen - 22.11.2025

Interview réalisée avec un Datascientist en personne:

On a un problème avec le chatbot, c'est à cause de la mauvaise qualité de données ?

Oui, vous créez un pipeline qui avale des erreurs : mots coupés, chiffres mal lus, tableaux désalignés... Ensuite, lorsque vous entraînez un modèle ou générez des visualisations, ces erreurs se propagent. C'est pour cela qu'un prétraitement rigoureux est indispensable : normalisation, correction des symboles, vérification des données numériques...

Quelle approche vous nous conseillez d'adopter alors dans ce cas-là ?

Si vous avez essayé l'extraction automatique mais que cela ne marche pas, il vaut mieux réorienter son approche. Le document a été peut être scanné de travers, compressé ou annoté, La méthode OCR permet de récupérer un "premier jet", puis il faut reconstruire le texte à la main ou semi-automatiquement. Le scraping n'est jamais entièrement automatique. Il faut accepter cette zone d'intervention humaine.

Qu'est que vous nous conseillez avec le temps restant (1h) avant le rendu final ?

Je vous recommande de générer les données synthétiques via l'IA parce que cela permettra de contourner le chaos des documents réels lorsque le but est de tester un concept. Dans votre hackathon, vous deviez démontrer la faisabilité d'un pipeline, pas encore produire une base parfaite. La génération IA permettra de produire des tables propres, cohérentes et structurées qui imitent fidèlement la forme des vraies données. Cela aide énormément lors des phases de prototypage.

Quels types de jeux de données peuvent être générés par l'IA dans ce contexte ?

Vous pouvez générer des tableaux statistiques, des blocs textuels résumant les résultats, mais aussi des données structurées alignées sur la syntaxe d'un fichier réel, par exemple, un tableau de résultats cliniques, ou un tableau "fact box" utilisé en risk literacy. Tant que la structure est respectée, ces données servent parfaitement de terrain d'essai.

À plus long terme, comment voyez-vous l'évolution de l'extraction scientifique par IA ?

On va vers des modèles capables de lire un PDF comme un humain, en combinant vision, langage et logique. Mais paradoxalement, la standardisation des formats sera tout aussi importante. Tant que les articles restent hétérogènes, les IA devront

continuer à improviser. C'est pour ça que l'open science et les formats ouverts vont devenir essentiels dans les années à venir.

Interview 3 :

Daniel Nissille le 22.11.2025

Retours de la discussion avec Madame Kerstin Preuschoff en personne:

La discussion orale n'a pas pu être enregistrée et est synthétisée ci-dessous le plus fidèlement possible.

Dans un premier temps, j'ai présenté au mieux la problématique que nous avions à aborder.

Madame K.Preuschoff a expliqué que la problématique était trop vaste et qu'elle faisait partie d'un enseignement dispensé sur au moins une année entière.

J'ai alors expliqué la démarche d'un pipeline général pour simplifier l'accès au risque:

Son retour fut alors d'expliquer que nous étions un peu trop optimistes. Pour étudier ou comprendre une problématique de risque il faut d'abord se concentrer sur un seul domaine d'étude et la catégorisation claire du risque. "Il faut toujours commencer par: quelle est votre définition du risque, de quel risque vous parlez?"

Je pense qu'à ce niveau il y a eu une discordance sur notre idée de simplifier la représentation des données d'une étude sur un risque X et le fait de concevoir un programme permettant de l'évaluer. Effectivement nous n'avons pas la connaissance pour évaluer un moindre risque présenté par une étude. En plus une démarche IA ne peut fonctionner que si elle est entraînée et les thématiques de risques étant diverses et de complexité différente il est probablement impossible d'entraîner un modèle global. La recommandation était donc de se concentrer sur un cas d'étude précis et donc un modèle spécifique. C'est-à-dire que chaque LLM doit être entraîné sur des données d'un domaine précis, ce qui impose en réalité de construire autant de pipelines qu'il y a de domaines d'études du risque. Mais cela dépassait de loin ce que nous avions entrepris.

J'ai donc abordé la thématique des démarches de risk literacy visant à représenter les données scientifiques de manière intuitive comme avec les "facts box" de Gerd Gigerenzer.

Madame Preuschoff a reconnu ne pas avoir entendu parler de ce modèle, mais la discussion fut toutefois encore plus enrichissante à ce moment précis alors que nous fûmes rejoints par les deux experts en IA.

J'ai présenté à nouveau la thématique et expliqué l'idée derrière les facts box. J'ai insisté sur le fait qu'elles ne sont aucunement un moyen de valider la qualité des données, mais permettent de les présenter avec le plus de clarté possible.

A ce point et avec le peu de temps restant, l'idée conductrice fut de nous focaliser sur un exemple le plus parlant possible afin d'illustrer notre démarche lors de la présentation. Il a aussi été évoqué qu'une bonne manière pour dédramatiser une impression de risque est de comparer ce risque avec un autre cas. L'exemple très clair mentionné fut de comparer les risques en avion par rapport à ceux de la voiture. En fait, il s'agit de contrecarrer un biais où la personne surestime des risques face à ce qui lui semble à tort moins risqué. Les facts box permettent justement de faire cela avec une très grande efficacité et démontreront à la personne à quel point elle a surestimé les risques de prendre l'avion par rapport à ceux de monter dans une voiture. "La partie la plus risquée lors de la prise de l'avion, c'est la route entre chez vous et l'aéroport."

Le cas du scraping de données a aussi ultimement été traité, là encore il n'est pas évident de définir un protocole global, les publications scientifiques utilisant une pléthore de représentations différentes. J'ai abordé l'exemple d'utiliser des données pour connaître le taux d'emploi à partir d'un cours, donc globalement une étude de risque déguisée. Mais nous en sommes revenu à la première étape, comment obtenir et synthétiser les données. Ce dernier point étant en réalité le facteur limitant de notre "problématique".

En conclusion, nous avons peu de temps pour aborder une problématique vraiment complexe et trouver une direction solide n'a pas été chose aisée. Cet échange très constructif bien qu'un peu tardif dans la journée explique notamment pourquoi nous avons parlé de voitures et d'avions et pas vraiment de l'apprentissage du risque permis par l'accès facilité aux données qui pourrait être très enrichissant pour l'enseignement. En outre, nous avons pu pleinement comprendre quels étaient les facteurs limitants et nous concentrer sur un cas précis et concret bien que peut être un peu hors sujet en définitif.

Bibliographie :

- 1) Cokely, E. T., Feltz, A., Ghazal, S., Allan, J. N., Petrova, D., & Garcia-Retamero, R. (2018). "Skilled Decision Theory: From Intelligence to Numeracy and Expertise." In K. A. Ericsson, R. R. Hoffman, A. Kozbelt, & A. M. Williams (Eds.), *The Cambridge Handbook of Expertise and Expert Performance* (pp. 476–505). chapter, Cambridge: Cambridge University Press. [en ligne] url: <https://www.cambridge.org/core/books/abs/cambridge-handbook-of-expertise-and-expert-performance/skilled-decision-theory-from-intelligence-to-numeracy-and-expertise/C7C6273C841BB197ABF5346F8527217C>
- 2) RiskLiteracy.org : <http://www.riskliteracy.org/>
- 3) Gigerenzer, G., & Kolpatzik, K. (2017). "How new fact boxes are explaining medical risk to millions." *BMJ* (Clinical research ed.), 357, j2460. <https://doi.org/10.1136/bmj.j2460>
- 4) How to do facts box: <https://www.hardingcenter.de/en/transfer-and-impact/fact-boxes>
- 5) Demicheli V, Jefferson T, Di Pietrantonj C, Ferroni E, Thorning S, Thomas RE, Rivetti A. «Vaccines for preventing influenza in the elderly. » *Cochrane Database of Systematic Reviews* 2018, Issue 2. Art. No.: CD004876. DOI: 10.1002/14651858.CD004876.pub4. Accessed 07 December 2025.
- 6) Inkscape Project. (2025). *Inkscape*. Retrieved from <https://inkscape.org>
- 7) Ayush Agrawal, Mirac Suzgun, Lester Mackey, and Adam Kalai. 2024. "Do Language Models Know When They're Hallucinating References?." In *Findings of the Association for Computational Linguistics: EACL 2024*, pages 912–928, St. Julian's, Malta. Association for Computational Linguistics. Accessed 21 December 2025
- 8) Test de Student: https://fr.wikipedia.org/wiki/Test_de_Student, Accessed 21 December 2025
- 9) Pixegami. *simple-rag-pipeline: A simple RAG pipeline that you can use as a starting point for learning about RAG (retrieval augmented generation)*. GitHub repository, 2025. Disponible en ligne : <https://github.com/pixegami/simple-rag-pipeline>
- 10) Nguyen, Nam Thang et al. (2025). *EduRisk Chatbot Prototype*. GitHub repository. Disponible en ligne : <https://github.com/Nam-ngn/HackademiA-2025-chatbot>

Figures:

Les figures 1 et 3 ont été générées avec ChatGPT : OpenAI. (2025). *ChatGPT* [Grand modèle linguistique]. Récupéré en décembre 2025, de <https://chat.openai.com/>.

La figure 2 a été tirée du Miro sur lequel les membres ont collaboré durant le hackathon. https://miro.com/app/board/uXjVJm24g6g=

La figure 4 a été construite à la main avec INKSCAPE voir référence [6]

Les figures 5,6,7,8,9 sont des captures d'écran du chatbot EduRisk voir référence [10]